

重庆市 AI 大模型创新应用大赛

语音克隆拟人化优化方案

从参考音频门禁到直播音色复用的质量方案

文档属性	内容
项目	汽车直播智能体
版本	v1.3
编制日期	2026 年 8 月
适用范围	竞赛答辩、技术评审、现场演示

质量原则 音色相似度首先由参考音频和参考文字决定，随机性参数只能做小范围稳定性校准。系统因此把“样本质量、文本一致、模型 profile、预热状态”作为一条完整的质量门禁。

文档修订记录

序号	版本号	修改时间	修改人	审核人	批准人	备注
1	V1.0	2026-09-15	项目组			按详细设计说明书模板 统一整理，补充目录、 修订记录和版式。

目录

1 引言..... 4

2 音色克隆总体设计..... 4

3 参考音频质量与质量门禁..... 4

4 音色 Profile 与数据结构..... 4

5 流式播报接口..... 5

6 性能与评测..... 5

7 合规、错误处理与运行规定..... 5

附录 A 参考资料..... 5

附录 B 扩充内容..... 7

 B.0 扩充内容说明..... 7

 B.1 克隆技术原理深入..... 7

 B.2 质量评估完整 Pipeline 8

 B.3 拟人化优化技术..... 9

 B.4 失败案例分析..... 11

 B.5 未来优化方向..... 12

1 引言

检查项	建议范围	不通过时
时长	3-10 秒，单人连续语音	提示重新选择片段
格式	24 kHz、单声道、16-bit PCM WAV	生成标准化副本
内容	普通话、无配乐、无明显混响	标记建议优化
文字	逐字参考文本与录音一致	禁止直接进入播报
电平	无削波，保留峰值余量	提示重新录制或优化

2 音色克隆总体设计

预检会计算 duration、channels、sample_width、sample_rate、active_ratio、silence_ratio、longest_silence、clipped_ratio、rms_db 和 peak_db，并将结果返回页面。对异常长内部静音只做温和压缩，保留短自然停顿，不强行降噪或改变频谱，避免“干净但不像”的过度处理。

指标	作用	门禁意义
active_ratio	有效人声占比	过低说明静音太多
longest_silence	最长内部静音	过长会影响节奏学习
clipped_ratio	削波比例	大于 0 可能带来电音
rms_db / peak_db	整体响度与峰值	避免输入过小或爆音
chars_per_second	文本与时长密度	检测参考文字是否匹配

3 参考音频质量与质量门禁

每个克隆音色保存 prompt_text、prompt_lang、model_profile、参考音频计数和采样参数。系统先将音色绑定到 base 或角色专用 profile，再预热 GPT-SoVITS；直播、试听、验证统一复用 profile，避免临时切权重造成首句卡顿和音色漂移。top_p、temperature、repetition_penalty 只在样本分析后做有限校准，优先保证音色和发音稳定。

4 音色 Profile 与数据结构

- 同一说话人可提供 1-2 条文本不同、音量接近的参考片段，用于增强音色覆盖。
- 不同说话人不得混用；系统按 voice_id 和 model_profile 隔离。
- 男声低频不足时，优先检查原音频是否经过压缩、背景音乐或过度降噪，再调整模型 profile。

- 角色化语气较强的样本需要同时准备平稳陈述句，避免模型把单一情绪误学成固定升调。

5 流式播报接口

阶段	动作	状态
上传	保存原文件，生成标准化副本	uploaded
分析	质量指标与参考文本校验	ready / needs_optimization
创建	绑定 GPT-SoVITS profile	warming
预热	调用一次短句并缓存模型状态	warmed
直播	使用同一 voice_id 进入 PCM 流	broadcast_ready

6 性能与评测

当前系统登记 6 套克隆音色，状态均为 ready；昔涟使用独立 xilian profile 和 v2ProPlus 微调权重，其他音色使用 base profile。机器验收覆盖格式和延迟，主观评测仍需至少 3 名听测者在同一设备、同一文案下填写音色相似度、清晰度、自然停顿、情绪节奏和整体拟人度。

验证项	结果	说明
克隆音色数量	6	voice profile 可切换
质量状态	ready	标准 PCM WAV
模型	v2ProPlus	本地 9880 服务
预热	warmed	直播首句减少冷启动
主观评测	待补 3 人	提交前填写评分

7 合规、错误处理与运行规定

- 只对获得授权的参考音频执行克隆；参赛材料不携带真实个人音频。
- 克隆音色默认本地保存，不自动上传第三方；若配置外部模型，需在部署说明中明确数据边界。
- 模型版本、权重路径和参考文本应随交付包记录，避免现场机器出现“同名不同模型”。

附录 A 参考资料

- GPT-SoVITS 官方中文说明：<https://github.com/RVC-Boss/GPT-SoVITS/blob/main/docs/cn/README.md>

- 参赛题目文件：C:/Users/seele/Desktop/6.（海云捷迅）2026 年第二届重庆市 AI 大模型创新应用大赛企业出题.docx

附录 B 扩充内容

B.0 扩充内容说明

B.1 克隆技术原理深入

特性	传统 TTS	克隆 TTS
音色数量	固定几种	无限
训练数据	每个音色需数小时录音	5-10 秒参考音频
训练时间	数天到数周	无需训练(推理时)
适应性	低	高
技术	独立模型	说话人编码器

方法	数据需求	训练时间	质量	本项目选择
Fine-Tuning	1 小时+	数小时	最佳	✗
Few-Shot	5-10 秒	无(推理)	优秀	✓

相似度评估方法:

方法 1: 说话人嵌入余弦相似度

```
def speaker_similarity(audio1, audio2):
    """计算两段音频的说话人相似度"""
    # 提取嵌入
    emb1 = speaker_encoder.encode(audio1)
    emb2 = speaker_encoder.encode(audio2)

    # 余弦相似度
    similarity = cosine_similarity(emb1, emb2)

    return similarity # 范围: [-1, 1], 通常 >0.85 视为相似
```

方法 2: 声纹识别模型

```
from resemblyzer import VoiceEncoder

encoder = VoiceEncoder()

def voiceprint_similarity(audio1, audio2):
    """基于声纹特征计算相似度"""
    emb1 = encoder.embed_utterance(audio1)
    emb2 = encoder.embed_utterance(audio2)

    return np.dot(emb1, emb2) # 已归一化, 直接点积
```

实际测试结果（昔涟音色）：

参考音频：昔涟原声 5 秒
合成音频：使用克隆音色合成“今天天气真不错”

说话人嵌入相似度：0.92
声纹识别相似度：0.89
主观 MOS 评分：4.5/5.0

结论：音色高度相似，可用于直播

B.2 质量评估完整 Pipeline




图 1 质量门禁流程

B -->	非 WAV	C[FFmpeg 转换]
E -->	<5s 或>10s	Fail1[拒绝: 时长不符]
E -->	5-10s	F[检查 2: 采样率]
F -->	<16kHz	Fail2[拒绝: 采样率过低]
F -->	≥16kHz	G[标准化处理]
I -->	否	Fail3[拒绝: 人声不足]
I -->	是	J
J -->	否	Fail4[拒绝: 静音过多]
J -->	是	K
K -->	否	Fail5[拒绝: 削波失真]
K -->	是	L
L -->	否	Warn1[警告: 噪音较大]
L -->	是	M
P -->	否	Fail6[拒绝: 文本不匹配]
P -->	是	Q[检查 5: 声纹相似度]
T -->	否且是新音色	U[通过: 新音色]

B -->	非 WAV	C[FFmpeg 转换]
T -->	否且是已有音色	Fail7[拒绝: 音色偏差]
T -->	是	U

分数	质量描述	自然度	清晰度	音色相似度	韵律
5	优秀	完全自然	每个字清晰	几乎分辨不出	抑扬顿挫自然
4	良好	基本自然	偶有模糊	明显相似	韵律流畅
3	一般	可接受	可理解	部分相似	略显僵硬
2	较差	机器感明显	部分难懂	相似度低	无韵律
1	很差	完全不自然	难以理解	完全不像	机械朗读

B.3 拟人化优化技术

韵律三要素：

- 1. 1. 节奏(Rhythm)：说话的快慢和停顿
- 2. 2. 音调(Pitch)：声音的高低变化
- 3. 3. 重音(Stress)：特定音节的强调

优化措施：

措施 1：标点驱动停顿

```
def add_prosody_marks(text):
    """根据标点添加韵律标记"""
    # 句号、问号、感叹号 → 长停顿
    text = text.replace("。", "。 [pause:500ms]")
    text = text.replace("?", "? [pause:500ms]")
    text = text.replace("!", "! [pause:500ms]")

    # 逗号、顿号 → 短停顿
    text = text.replace(",", ", [pause:200ms]")
    text = text.replace("、", "、 [pause:150ms]")

    # 冒号 → 中等停顿
    text = text.replace(":", ": [pause:300ms]")

    return text
```

措施 2：情感标记

支持的情感标记

```
emotions = {

    "[激动]": {"pitch": +0.2, "speed": 1.1, "volume": 1.2},
```

```
"[平静]": {"pitch": -0.1, "speed": 0.95, "volume": 0.9},
"[疑问]": {"pitch": +0.3, "speed": 1.0, "volume": 1.0},
"[强调]": {"pitch": +0.1, "speed": 0.9, "volume": 1.3}
}
```

使用示例

```
text = "[激动]这款车的性能真的太棒了！"
```

****措施 3：重音标记****

原文：“这款车续航 610 公里”
标记：“这款车续航[stress]610 公里[/stress]”
效果：“610”被强调，音调升高音量增大

参数	平淡	自然	丰富	夸张
temperature	0.3	0.66	0.85	1.0
top_p	0.5	0.72	0.85	0.95
pitch_variance	低	中	高	很高

音色三维调整：

```
class VoiceProfile:
    """音色配置文件"""
    def __init__(self, name):
        self.name = name

        # 基础参数
        self.reference_audio = None      # 参考音频路径
        self.speaker_embedding = None    # 256 维嵌入向量

        # 韵律参数
        self.speed_factor = 1.0           # 语速 (0.5-2.0)
        self.pitch_shift = 0              # 音调 (-12 ~ +12 半音)
        self.volume_gain = 1.0           # 音量 (0.5-2.0)

        # 情感参数
        self.temperature = 0.66           # 随机性
        self.top_p = 0.72                 # 采样多样性
        self.top_k = 18                   # 采样范围

        # 高级参数
        self.use_prompt_text = False      # 是否使用语义提示
```

```
self.delivery_style = "warm"      # 风格: warm/professional/casual
```

典型音色配置示例:

昔涟音色 - 温暖亲切

```
xilian_profile = VoiceProfile("xilian")
```

```
xilian_profile.speed_factor = 1.0
```

```
xilian_profile.pitch_shift = 0
```

```
xilian_profile.temperature = 0.66
```

```
xilian_profile.delivery_style = "warm"
```

专业播报音色 - 沉稳可信

```
professional_profile = VoiceProfile("professional")
```

```
professional_profile.speed_factor = 0.95 # 略慢
```

```
professional_profile.pitch_shift = -2    # 略低沉
```

```
professional_profile.temperature = 0.50 # 更稳定
```

```
professional_profile.delivery_style = "professional"
```

活力音色 - 年轻热情

```
energetic_profile = VoiceProfile("energetic")
```

```
energetic_profile.speed_factor = 1.10    # 略快
```

```
energetic_profile.pitch_shift = +3       # 略高
```

```
energetic_profile.temperature = 0.75     # 更生动
```

```
energetic_profile.delivery_style = "casual"
```

B.4 失败案例分析

问题: 用户上传 3 秒参考音频

表现: 音色不稳定, 有时偏离

原因: 音频太短, 说话人嵌入信息不足

解决: 拒绝上传, 提示需要 5-10 秒

问题: 参考音频包含背景音乐

表现: 合成音频带有“音乐感”的韵律

原因: 编码器将音乐也编码到嵌入中

解决: 质量检查识别音乐(频谱分析), 拒绝上传

问题: 参考音频是两人对话

表现: 音色不一致, 有时像 A 有时像 B

原因: 编码器混淆了两个说话人

解决：ASR 检测多说话人，拒绝上传

问题：手机录音削波严重
表现：合成音频有破音和失真
原因：输入失真被学习到嵌入中
解决：削波检测(`clipped_ratio>1%`)，拒绝上传

问题：参考音频带有明显方言口音
表现：合成音频也带口音，可能影响清晰度
评估：不一定是失败，看需求

- 如果要保留个性 → 接受
- 如果要标准普通话 → 建议重录

处理：提供“口音强度”评估，让用户决定

B.5 未来优化方向

当前：需要 5 秒参考音频
未来：仅需文字描述即可生成音色
 例：“30 岁女性、温柔、略带沙哑”
技术：Bark、AudioLM 等

当前：整体情感标记(`[激动][平静]`)
未来：字/词级情感控制
 例：“这款车`[惊喜]`真的`[强调]`太棒了！”
技术：多情感编码器

当前：预先克隆音色
未来：实时语音转换
 主播真人说话 → 实时转换为目标音色
技术：Voice Conversion 技术

当前：仅基于文本
未来：结合表情、手势驱动情感
 数字人表情 → 语音情感同步
技术：多模态融合