

重庆市 AI 大模型创新应用大赛

系统设计说明书

面向汽车销售直播的本地智能体技术设计说明书

文档属性	内容
项目	汽车直播智能体
版本	v1.2
编制日期	2026 年 8 月
适用范围	竞赛答辩、技术评审、现场演示

设计结论 系统以本地可控为主线，把知识入库、检索问答、流式语音和动态改稿放在同一条可追踪链路中。比赛现场可从资料导入一路演示到文字与语音输出。

1 项目概述

汽车直播的核心矛盾不是单纯生成文本，而是在资料变化快、直播节奏快、主播需要随时改稿的情况下，仍要保证答案有出处、语音能连续播放、修改不会截断正在播报的句子。本项目提供一个运行在本机的智能体原型，覆盖“资料导入 - 检索问答 - 脚本播报 - 动态修订 - 音色管理”五个环节。

1.1 建设目标

- 让 PDF、DOCX、TXT 资料可以批量导入、清洗、分段、结构化保存，并保留文档、页码、版本等证据。
- 让检索问答输出答案、置信度和来源片段，测试样本不少于 40 条，准确率目标不低于 85%。
- 让脚本在音频生成的同时开始播放，首个可播放音频延迟不超过 3 秒；改稿只影响尚未播放的后续内容。
- 让授权参考音频经过质量门禁和 v2ProPlus 推理链路后接入直播台，多套音色可切换，失败时保留文字和浏览器语音回退。

1.2 业务边界

范围	本项目负责	明确不负责
资料	公开车型资料的导入、检索、来源展示	未经授权的内部政策与个人资料外发
语音	参考音频克隆、PCM 流式播报、质量诊断	替代专业录音棚或大规模训练平台
直播	脚本播报、动态改稿、问答语音	自动控制第三方直播平台账号

2 总体架构

系统采用前后端分层和本地服务组合。浏览器只负责交互和音频排程；FastAPI 负责会话、版本、检索和流式接口；SQLite 负责可追踪数据；GPT-SoVITS 负责克隆音色和生成 PCM WAV。模块之间以 HTTP/JSON 和流式字节协议连接，便于现场替换单个组件。

层次	模块	输入/输出	故障策略
交互层	直播台、知识库、验证页	文本、文件、音频控制	TTS 不可达时保留文字
业务层	脚本会话、动态改稿、问答编排	会话版本、检索结果	使用本地抽取式问答
数据层	SQLite 文档、片段、版本、音色	结构化记录与溯源	保留原始文件和版本
模型层	GPT-SoVITS v2ProPlus	参考音频 + 文本 -> PCM	回退预置音色或浏览器语音

2.1 关键数据流

- 资料流：文件上传 -> 类型解析 -> 文本清洗 -> 片段切分 -> 哈希向量 / 词法索引 -> SQLite -> 检索结果带来源。
- 播报流：脚本文本 -> 自然停顿切分 -> 请求 GPT-SoVITS -> 去 WAV 头 -> PCM 播放队列 -> 句间短淡入淡出。
- 改稿流：编辑器产生新版本 -> 计算当前安全边界 -> 取消未提交请求 -> 从下一个自然短语重新生成 -> 播放队列继续。
- 音色流：参考音频预检 -> 标准化 PCM 副本 -> 文本一致性校验 -> 音色记录与模型 profile -> 预热 -> 试听 / 直播复用。

3 功能与模块设计

3.1 知识库与问答

导入器支持 PDF 页面文本、DOCX 段落与表格、TXT/MD 纯文本。清洗阶段统一空白、去除孤立符号并按标题、标点和长度进行分段；结构化元数据包含品牌、车系、年款、文档版本和来源位置。检索采用词法命中与稳定哈希向量混合排序，答案生成优先使用字段级抽取，避免模型在关键参数上自行补写。

3.2 流式 TTS 与动态改稿

播报默认使用 GPT-SoVITS v2ProPlus 的 mode 1 PCM 流。后端以自然停顿为边界形成约 16-20 字的短语，首个短语到达即发送；前端把后续 PCM 接入同一 AudioContext 的播放队列。句首和句尾使用 2 ms 淡入淡出，减少硬切造成的嗒声。改稿时保存会话版本和当前播放短语，只有安全边界之后的内容刷新。

3.3 音色克隆

参考音频需为单人、无配乐、普通话、逐字文本一致的 3-10 秒片段。系统会检测采样率、声道、位深、有效人声比例、静音比例、最长静音、响度、削波和文本时长密度；只生成标准化副本，不覆盖原文件。通过门禁后，音色以 voice profile 形式进入 GPT-SoVITS 请求，并在切换到直播前完成预热。

4 接口与状态

接口	用途	关键返回
POST /api/documents/import	批量导入资料	document_id、片段数、版本
POST /api/query	车型检索问答	answer、confidence、sources[]

POST /api/tts/stream	自然短语 PCM 流	首包字节、音频分片
POST /api/voices/analyze	音频质量预检	quality、metrics、advice
POST /api/voices/clone	创建克隆音色	voice_id、profile、warming
POST /api/voices/{id}/optimize	生成优化副本	optimized_path、quality

5 可靠性、安全与合规

- 推理互斥：TTS 单模型推理锁避免预热、试听、验证和直播并发触发 GPT-SoVITS 限制。
- 可恢复：服务健康检查、启动脚本防重复锁、GPT-SoVITS 不可达时回退浏览器语音。
- 数据最小化：上传资料和参考音频默认仅保存在本机；外部大模型只有用户主动配置地址后才接收检索片段。
- 授权边界：参赛发布前删除真实个人音频和未授权资料；参考音频克隆仅用于获得授权的角色或主播。

6 验收指标与当前实测

指标	目标	实测	结论
检索准确率	>=85%，样本 >=40	40/40，100%	达标
最终问答准确率	>=85%，样本 >=40	40/40，100%	达标
TTS 首音频延迟	<=3000 ms	平均 2323 ms	达标
动态改稿	当前句不截断	版本 1 -> 2，安全句 1	达标
单元测试	无失败	35/35 passed	达标

7 部署拓扑与演示入口

服务	地址	作用
前端	http://127.0.0.1:5173	直播台、知识库、验证页
后端	http://127.0.0.1:8000	FastAPI 业务接口与 /docs
GPT-SoVITS	http://127.0.0.1:9880	v2ProPlus 克隆与合成
数据	data/、SQLite	示例资料、上传副本、版本记录

参考资料

- GPT-SoVITS 官方中文说明：<https://github.com/RVC-Boss/GPT-SoVITS/blob/main/docs/cn/README.md>
（零样本约 5 秒、少样本约 1 分钟、环境与模型说明）
- 参赛题目文件：C:/Users/seele/Desktop/6.（海云捷迅）2026 年第二届重庆市 AI 大模型创新应用大赛企业出题.docx（功能、指标与提交要求）