

流式 TTS 与动态改稿实现方案

面向直播场景的边生成边播放与安全刷新机制

文档属性	内容
项目	汽车直播智能体
版本	v1.2
编制日期	2026 年 8 月
适用范围	竞赛答辩、技术评审、现场演示

工程取舍 系统默认选择 mode 1 PCM 流，把连续播放和稳定性放在首位；mode 2/3 可作为低延迟设备的显式实验选项，不作为比赛现场默认路径。

1 需求拆解

要求	可验证定义	实现位置
边生成边播放	收到首个自然短语 PCM 即开始排程	后端 /api/tts/stream + 前端 AudioContext
动态改稿	当前短语播放完成后，后续内容替换	会话版本与安全边界
首音频延迟	从请求开始到首个可播放 PCM 字节	验证页 TTS 测试
低噪与连续	PCM 边界无硬切，句间停顿稳定	2 ms 淡入淡出 + 队列

2 播报时序

- 前端提交脚本、voice_id、语速、音量和语调参数。
- 后端按中文标点、连接词和约 16-20 字上限切分自然短语，建立 session_id 和 chunk_index。
- 后端请求 GPT-SoVITS mode 1，收到首个 WAV 分片后剥离 WAV 头，转成 24 kHz 单声道 PCM。
- 前端创建 AudioBufferSourceNode，串行设置 start_time；后续分片不等待全文完成。
- 当前短语结束后插入短自然停顿，下一片接续；出错时保留已播放内容并尝试重试或回退。

时刻	后端	前端	可观测指标
T0	创建会话、切分文本	显示播放中	session_id
T1	首个 PCM 到达	创建首个音频节点	first_audio_ms
T2	后续片段生成	追加播放队列	queue_depth
T3	用户改稿	提交新版本	revision
T4	安全边界	切换新稿后续	safe_sentence

3 动态改稿算法

会话状态包括 revision、当前播放 chunk、已排程 chunk 和待生成 chunk。用户点击“应用动态改稿”时，系统先记录当前已播放或正在播放的自然短语，再取消 revision 之前未排程的请求。新的脚本从安全边界重新切分并生成，当前短语不被回收，因此不会出现半个字被截断或重复播报。

安全边界 “当前正在播放的短语”是不可变区；“尚未开始播放的后续片段”是可变区。该边界既满足实时改稿，又避免用户听到音频突然跳变。

4 电子嗒声与卡顿治理

现象	常见原因	本项目处理
嗒声	PCM 硬切、前后片段直流偏置不同	片段边界 2 ms 淡入淡出、统一格式
首句卡顿	模型切权重、冷启动、多个请求并发	voice profile 预热、单模型推理锁
句间过长	按逗号机械切分、每段串行等待	自然短语切分、连续排程
音色漂移	参考文本不一致或 profile 未复用	文本密度门禁、音色 profile 绑定

5 性能与验收

样本	首音频延迟	状态
欢迎来到汽车直播间。	2266.4 ms	通过
今天为大家介绍这款车型的续航和智，	2615.9 ms	通过
如果你想了解购车政策，	2086.6 ms	通过
平均	2323.0 ms	<=3000 ms

6 现场操作与故障回退

- 先在直播台播放三句话脚本，第一句播放期间修改第三句并应用，观察当前句完整结束、后续句使用新稿。
- 若 GPT-SoVITS 暂时不可达，页面保留文字答案并回退浏览器语音；恢复后可重新选择克隆音色。
- 若首包超过 3 秒，检查是否同时运行多套 9880 服务或有其他 GPU 推理任务。

参考资料

- GPT-SoVITS 官方中文说明：<https://github.com/RVC-Boss/GPT-SoVITS/blob/main/docs/cn/README.md>
- 参赛题目文件：C:/Users/seele/Desktop/6.（海云捷迅）2026 年第二届重庆市 AI 大模型创新应用大赛企业出题.docx